

Green AI: métricas para eficiência energética e sustentabilidade dos algoritmos de inteligência artificial e data centers

Ivini Ferraz

Rua Carlos Escobar, 128. Sala 43. São Paulo-SP, Brasil (CEP 02130-050).

Resumo. A inteligência artificial (IA) tem impulsionado avanços tecnológicos significativos em áreas como saúde, agricultura e energia. No entanto, seu crescimento exponencial apresenta desafios relevantes em relação ao impacto ambiental. Grandes *data centers* ao redor do Mundo tornaram-se grandes consumidores de energia e emissores de carbono, atingindo níveis comparáveis ao consumo energético de cidades ou até mesmo de países inteiros. O presente artigo explora publicações recentes na área de computação de alto desempenho (HPC). Foram analisadas e comparadas diferentes métricas, indicadores de desempenho energético, abordagens metodológicas e técnicas voltadas para a promoção de uma IA mais sustentável (*Green AI*). Os resultados indicam o surgimento de um campo científico historicamente paradoxal, que busca conciliar a eficiência energética e a sustentabilidade diante do aumento dos *data centers* e do uso intensivo de *tokens*, *prompts*, dados e algoritmos, necessários para o treinamento e a produtividade de modelos de IA.

Palavras-chave: Inteligência artificial; *Green AI*; Sustentabilidade; *Data centers*; IA responsável.

Abstract. *Green AI: Metrics for energy efficiency and the sustainability of artificial intelligence algorithms and data centers.* Artificial intelligence (AI) has been driving significant technological advancements in areas such as health, agriculture, and energy. However, its exponential growth presents relevant challenges regarding environmental impact. Large data centers around the World have become major energy consumers and carbon emitters, reaching levels comparable to the energy consumption of cities or even entire countries. This article explores recent publications in the field of high-performance computing (HPC). Different metrics, energy performance indicators, methodological approaches, and techniques aimed at promoting more sustainable AI (*Green AI*) were analyzed and compared. The results indicate the emergence of a historically paradoxical scientific field that seeks to reconcile energy efficiency and sustainability in the face of the increasing number of data centers and the intensive use of tokens, prompts, data, and algorithms required for training and productivity in AI models.

Recebido
21/10/2024

Aceito
20/12/2024

Publicado
31/12/2024



Acesso aberto



ORCID

0009-0000-0094-4165
Ivini Ferraz

Keywords: Artificial intelligence; Green AI; Sustainability; Data Centers; Responsible AI.

Introdução

A inteligência artificial (IA) e sua indústria vêm experimentando um crescimento explosivo nesta década, impulsionando uma demanda crescente de *data centers* para o treinamento e a hospedagem de modelos, aplicações e tecnologias, que começam a ser disponibilizadas para um grande público de consumidores.

Segundo Gartner (2024), o *hype cycle* das tecnologias é iniciado com a descoberta de uma tecnologia, fomentando uma fase de grande entusiasmo. Enquanto ainda não existem produtos disponíveis no mercado, seus potenciais consumidores experimentam um *pico de expectativas exageradas* até encontrar o *vale da desilusão*. Após a derrocada das expectativas, uma nova subida de consolidação (*slope of enlightenment*) torna mais evidente quais são, de fato, as melhores práticas. Finalmente, algumas tecnologias têm a capacidade de atingir um *platô de produtividade*, onde atingem o seu estágio de maturidade, sendo amplamente adotadas pela sociedade (Figura 1).




Figura 1. O *hype cycle* das tecnologias. Fonte: Gartner (2024).

A sustentabilidade das tecnologias emergentes tem sido, historicamente, relegadas a um segundo plano. Nesta década de 2020, as tecnologias de IA, dentre as quais a IA Generativa, alcançarão um *platô de produtividade*, aumentando significativamente o consumo de energia, a demanda por água e a quantidade de emissões de CO₂.

Segundo o Databricks (2024), houve um crescimento de 1.018% de modelos de IA registrados em 2024, em nível empresarial. Os *Large Language Models* (LLMs), como GPT-4, Bert e Gemini, consomem quantidades de energia equivalentes a grandes cidades. De acordo com Strubell et al. (2019), o treinamento de grandes modelos de IA pode resultar na emissão de grandes quantidades de CO₂. Estes valores são incrivelmente expressivos, quando se observam as emissões das *big techs*.

De acordo com o relatório do Google (2024), as emissões de carbono da empresa aumentaram quase 50%, em comparação com 2019, em grande parte por conta dos treinamentos de IA e seu uso comercial. A Microsoft (2023) também relatou que suas emissões aumentaram em quase 30%, desde 2020, principalmente devido à construção de novos *data centers*.

Devido a este crescimento, estima-se que o período até 2030 será desafiador para o setor de tecnologias e grandes *data centers* (Uptime Institute, 2022) e que haverá grandes dificuldades para o cumprimento das metas estabelecidas pela legislação na Europa, Singapura e Estados Unidos, líderes do mercado global.

A ausência de métricas de eficiência e de regulação do mercado de *data center*, somadas ao potencial para a produção de energia limpa (Global Energy Monitor, 2024), torna o Brasil um dos países mais promissores para o investimento em centro de dados (Lopes, 2024).

Tendo em vista este contexto, o objetivo desta pesquisa é investigar e analisar as principais métricas, indicadores de eficiência energética, abordagens metodológicas e técnicas voltadas para a promoção de práticas sustentáveis em inteligência artificial, com base no conceito de *Green AI*, bem como compreender os desafios associados ao aumento exponencial do consumo de energia e das emissões de carbono em *data centers*, propondo caminhos para a conciliação entre a eficiência energética e a sustentabilidade no desenvolvimento e uso de algoritmos de IA e suas aplicações.

Metodologia

Esta pesquisa adota uma abordagem metodológica interdisciplinar e exploratória, através de revisão de literatura abrangente e atualizada, focada no movimento acadêmico *Green AI*, iniciado em 2019, que vem ganhando força com a proposta de difundir técnicas de computação de alto desempenho, capazes de minimizar a pegada ecológica da indústria do algoritmo.

A ideia de realizar uma revisão sistemática das publicações da *Green AI* foi abandonada, considerando que essa análise foi desenvolvida recentemente por Verdecchia et al. (2023), cuja pesquisa oferece uma excelente contextualização dos artigos e temas discutidos pelos autores da área.

A descarbonização ou a neutralização da IA depende de metodologias assertivas para o cálculo de emissões geradas pelos *data centers*. Observa-se a presença de dois parâmetros fundamentais para o cálculo: o consumo de energia e o consumo de água potável (Li et al., 2023).

Neste artigo, será abordado, exclusivamente, o problema da eficiência energética e das emissões de carbono, deixando o consumo de água dos *data centers* para uma pesquisa futura.

Resultados e discussão

***Green AI*, um movimento científico em prol de uma IA sustentável**

A expressão *Green AI* foi popularizada por Schwartz et al. (2019), que propõem uma nova abordagem para a pesquisa em inteligência artificial e criticam as pesquisas que priorizam a maximização da precisão dos modelos, negligenciando os custos energéticos e computacionais associados ao treinamento e à execução destas tecnologias.

A *Green AI* é uma resposta à chamada *Red AI*, que ignora a sua pegada de carbono, focando exclusivamente na otimização dos algoritmos, que resulta no uso exorbitante de dados e em sistemas computacionais cada vez mais complexos, gerando, conseqüentemente, impactos ambientais significativos (Team Ciente, 2024).

Cálculo do consumo energético (pegada energética)

A emissão de carbono está diretamente relacionada ao consumo de energia e à sua fonte. Cada quilowatt-hora (kWh) de eletricidade consumido está associado a uma quantidade de emissões de CO₂, que varia de acordo com a matriz energética utilizada. Se a matriz é proveniente de combustíveis fósseis não renováveis, as emissões de CO₂ serão significativamente maiores, mesmo se considerada a mesma quantidade de energia.

Por esta razão, para calcular o impacto das emissões de CO₂, utiliza-se o “*fator de emissão*”, que é expresso em gramas de CO₂ por kWh (g CO₂/kWh). Esse fator é normalmente publicado por órgãos ou agências ambientais governamentais e pode ser utilizado para estimar as emissões relacionadas ao consumo de eletricidade.

No Brasil, a Empresa de Pesquisa Energética (EPE, 2024) utiliza o fator de emissão de CO₂ para eletricidade para calcular aquelas associadas ao uso de energia elétrica. Esse fator é divulgado em relatórios técnicos, como o Balanço Energético Nacional (BEN) e deve ser calculado com base em informações sobre a matriz energética do país e dados fornecidos pelo Operador Nacional do Sistema Elétrico (ONS).

Para calcular as emissões de carbono associadas ao uso de eletricidade, é usada a fórmula:

$$E_c = P_e \times F_c$$

Onde:

E_c = emissão total de carbono;

P_e = consumo de energia; e

F_c = fator de emissão de carbono.

O mercado de *data centers* (Figura 2) é altamente dependente de eletricidade, sendo importante monitorar seu crescimento regional e o consumo de energia.




Figura 2. Geolocalização dos mercados primários (pontos verdes), secundários (pontos lilases) e emergentes (pontos vermelhos) de *data center*. Fonte: Duncan et al. (2024).

Tamanho do mercado mundial de *data centers* 2024 (MW)

O tamanho do mercado de *data center* pode ser medido em MW, que indica a capacidade de carga crítica de tecnologia da informação (TI), mostrando a quantidade de energia necessária para suportar a operação de seus servidores e máquinas (Duncan et al., 2023).

PUE data center globais

A Figura 3 apresenta a evolução do *Power Usage Effectiveness* (PUE) médio anual dos maiores *data centers* do Mundo, entre 2007 e 2023. O PUE é uma métrica tradicionalmente utilizada para avaliar o desempenho energético dos *data centers*, medindo a relação entre a energia total consumida (incluindo a usada na refrigeração) *versus* a energia usada no processamento dos equipamentos. Nesta equação, quanto menor o PUE, maior a eficiência energética.




Figura 3. PUE data center globais. Fonte: Uptime Institute (2022); Duncan et al. (2024).

Pode ser observado na Figura 3 que o PUE cai de 2,5, em 2007, para cerca de 1,6, em 2023, indicando uma melhoria na eficiência energética. Contudo, essa diminuição do PUE não torna o mercado de *data centers* uma indústria de *baixo carbono* porque outros fatores, como a matriz energética e o impacto da pegada hídrica, comprometem essa classificação.

Esse fenômeno reflete o clássico *Paradoxo de Jevons*, ou *efeito bumerangue*, no qual a eficiência energética reduz custos operacionais, ao mesmo tempo em que gera maior demanda, neutralizando os ganhos ambientais (Alcott, 2005).

Esse paradoxo é extremamente relevante em indústrias tecnológicas, como os *data centers*, veículos elétricos, computação em *cloud*, onde a melhoria na eficiência pode resultar em maior demanda pelo serviço ou produto, e, conseqüentemente, em um aumento no uso total dos recursos energéticos (de Vries, 2023).

Índice PUE x consumo de energia nos data centers (*Paradoxo de Jevons*)

Nota-se, na Figura 4, que, entre 2010-2016, o consumo de energia pelos *data centers* permaneceu relativamente estável, em torno de 200 TWh anuais. Apesar do aumento de demanda, a otimização da eficiência energética estabilizou o consumo. Somente a partir de 2017 é que o aumento do consumo de energia torna-se exponencial, devido à alta demanda computacional dos modelos de IA Generativa e aumento de dados necessários para o seu treinamento.




Figura 4. PUE *data center* globais x consumo de energia.

O PUE quando apresentado isoladamente, pode tornar-se uma *métrica da vaidade*. No contexto dos *data centers*, o termo mais adequado seria *misleading metric* (métrica enganosa).

Para uma visão mais abrangente da eficiência energética da infraestrutura, as organizações técnicas precisarão de métricas adicionais que abordem o desempenho energético de TI. Esta é uma tarefa consideravelmente mais complexa do que medir o PUE. Um grande desafio é estabelecer uma linha de base, pois não há um método claro para quantificar a quantidade de trabalho que o TI realiza. Também é difícil isolar a energia usada para realizar o trabalho das perdas parasitárias [...] dentro do consumo de energia de TI (Uptime Institute, 2022, p. 7).

Cálculo de emissão durante a inferência (*Prompts*)

Segundo Berdardo et al. (2022), estudos sobre a execução de algoritmos de IA, *machine learning* e redes neurais artificiais (RNAs) tornaram-se tarefas essencialmente complexas para diferentes pesquisadores de *High Performance Computing* (HPC).

Afinal, não é tarefa fácil realizar uma comparação direta da performance de algoritmos, durante seu treinamento e inferências, calculando o consumo de energia e água em diferentes arquiteturas físicas computacionais. Não existem padrões uniformes de hardware, software e condições climáticas previamente estabelecidos.

Para avaliar as emissões de carbono dos *Large Language Models* (LLMs) é preciso analisar uma exorbitante quantidade de parâmetros, algoritmos e inferências, sendo este um campo de estudo em desenvolvimento inicial.

Nos modelos de IA, como o GPT-3, um *prompt* é a entrada fornecida ao modelo para gerar uma resposta ou realizar uma *inferência*. Assim, usa-se o *prompt* para iniciar uma consulta ou *command*, que desencadeia o processamento de informações no modelo de IA. A Figura 5, representa o *modelo de emissão* segundo o *tipo de tarefa de inferência*, criado por Luccioni et al. (2023). Ou seja, a complexidade do *prompt* vai definir o tipo de tarefa de inferência, o consumo energético e a emissão de carbono do usuário.




Figura 5. Emissões de carbono por tipo de tarefas. Fonte: Luccioni et al. (2023), Stanford University (2024, p. 156).

Emissão de carbono durante inferências modais

É importante destacar que a inferência (o uso direto dos modelos pelos usuários de IA) sucede as etapas de desenvolvimento e treinamento das IAs. Segundo Strubell et al. (2019), o treinamento de um único modelo de IA pode emitir até 284 t de CO₂, que equivale à emissão de cinco automóveis ao longo de toda sua vida útil.

Por isso, os pesquisadores da *Green AI* (e.g. Schwartz et al., 2019) argumentam que as métricas de eficiência devem ser incorporadas pelos pesquisadores desde o momento da concepção até o fim do treinamento dos modelos. Para esses autores, a sustentabilidade ambiental dos modelos só será possível se as métricas de eficiência corresponderem aos critérios de avaliação das pesquisas.

A seguir são destacadas as principais métricas da *Green AI*, segundo Schwartz et al. (2019):

1. **Número de parâmetros:** Modelos maiores, como o GPT-3.5, possuem mais parâmetros e, portanto, demandam mais energia para seu treinamento.
2. **PUE (eficiência energética):** *Data centers* com PUEs mais altos desperdiçam mais energia e, portanto, geram mais emissões de carbono.
3. **Intensidade de carbono da rede:** A quantidade de CO₂ emitida por kWh de eletricidade consumida, medida em g CO₂eq/kWh. Fontes renováveis têm intensidades mais baixas do que os combustíveis fósseis.
4. **Temporeal transcorrido:** Tempo de execução necessário para gerar os resultados de inferência. Reflete a eficiência dos modelos e algoritmos, porém é muito influenciado pela capacidade dos hardwares.
5. **FPO (Floating Point Operations):** Mede a eficiência computacional de um modelo a partir do número de operações aritméticas em ponto flutuante necessárias para a execução de um modelo.

Estudos tecnicamente aprofundados são capazes de identificar a eficiência energética de algoritmos pelo tempo-espaço. Uma das pesquisas pioneiras no Brasil, no campo de *Hight Performace Computing* (HPC), realizado por Berdardo et al. (2022), buscou calcular o tempo de execução dos algoritmos, em diferentes arquiteturas computacionais, usando a fórmula:

$$EDP = E \times D$$

Onde:

EDP = Energy delay product (J/s);

E = Energia (J); e

D = Delay (s)

Luccioni et al. (2023) reuniram métricas diversificadas para avaliar o impacto ambiental dos modelos durante a inferência, como sintetizado na Tabela 1.

Tabela 1. Impacto ambiental de modelos de *machine learning* selecionados.

Modelo	Número de parâmetros	PUE do <i>data center</i>	Intensidade de carbono da rede	Consumo de energia	Emissão de CO ₂ eq	Emissão de CO ₂ eq x PUE
Gopher	280B	1,08	330 gCO ₂ eq/kWh	1.066 MWh	352 t	380 t
BLOOM	176B	1,20	57 gCO ₂ eq/kWh	433 MWh	25 t	30 t
GPT-3	175B	1,10	429 gCO ₂ eq/kWh	1.287 MWh	502 t	552 t
OPT	175B	1,09	231 gCO ₂ eq/kWh	324 MWh	70 t	76,3 t

Fonte: Luccioni et al. (2023), Maslej et al. (2023) e Stanford University (2024).

Impacto ambiental de quatro modelos selecionados

Nota-se que, entre os quatro modelos analisados, o GPT-3 apresentou as maiores emissões de carbono, liberando 1,4 vezes mais do que o Gopher, 7,2 vezes mais do que o OPT e 20,1 vezes mais do que o BLOO.

Abordagens para otimização dos modelos de IA

Pesquisadores da *Green AI*, como Clemm et al. (2024) defendem uma abordagem holística, que se inicia pela avaliação de todo o ciclo de vida, da extração de materiais para servidores até o descarte dos resíduos. Esse método, conhecido como *pensamento sistêmico de ciclo* sugere uma análise mais detalhada sobre os hardwares e softwares envolvidos no processamento de IA.

Além da adoção das métricas propostas pela *Green AI*, é necessário propor inovações metodológicas e boas práticas para torná-la uma tecnologia viável e apta a atingir um platô de produtividade e escala.

Entre as principais abordagens metodológicas da *Green AI* destacam-se três:

- 1) *Green AI* centrada em otimização de hiperparâmetros (Stamoulis et al., 2018);
- 2) *Green AI* centrada em simplificações de algoritmos de árvore de decisão (García-Martín et al., 2019); e
- 3) *Green AI* centrada em dados, que foca na otimização dos dados, em vez de se concentrar exclusivamente nos algoritmos (Verdecchia et al., 2021).

Clemm et al. (2024) buscam incentivar desenvolvedores a otimizar modelos por meio de ferramentas de cálculo, compressão, quantização e *knowledge distillation*.

Algumas calculadoras de emissões vêm sendo desenvolvidas por entusiastas da *Green AI*, sendo uma das mais conhecidas o *carbon tracker* (García-Martín et al., 2019), que propõe o “monitoramento em tempo real do consumo de energia e das emissões de carbono durante o treinamento de modelos de aprendizado profundo”.

Ainda que a computação quântica esteja longe de atingir um platô de produtividade (Gartner, 2024). Dutta et al. (2024) defendem que, com a aplicação de técnicas quânticas, como as *Attention-Enhanced Quantum Physics-Informed Neural Networks* (AQ-PINNs), haverá uma significativa redução no número de parâmetros.

Na visão destes autores, a computação quântica tem um grande potencial para reduzir o problema clássico discutido no *Paradoxo de Jevons* e contribuir para uma IA mais sustentável, em alinhamento com os princípios da *Green AI*.

Considerações finais

A pegada energética do mercado de *data centers* e sua ampliação devido ao desenvolvimento acelerado de LLMs, tecnologias *blockchain*, visão computacional, Internet 6G, entre outras, leva a uma percepção alarmante sobre os reais impactos ambientais da digitalização nesta década.

Neste contexto, o movimento *Green AI* defende a adoção de práticas sustentáveis e métricas coerentes, a partir da conscientização e do envolvimento de desenvolvedores, pesquisadores e gestores de diferentes setores sobre a necessidade de adotar algoritmos, sistemas e *hardwares* que, além de rápidos e precisos, sejam mais leves e ecológicos.

As métricas isoladas, como o *Power Usage Effectiveness* (PUE), mascaram a pegada de carbono dos *data centers* e o uso excessivo de energia pelo setor.

A exemplo da União Europeia, o impacto ambiental dos *data centers* deve ser uma pauta prioritária na regulamentação da IA em todos os continentes, até que instalações com emissões zero tornem-se critério para financiamento e compras públicas de infraestrutura de computação.

Além disso, a regulamentação e operação do mercado de carbono, bem como as políticas de resíduos sólidos, regulação da IA e eficiência energética, no Brasil e no Mundo, podem ser cruciais para a mitigação do impacto ambiental dos *data centers*.

Os movimentos de caráter científico, como o *Green AI*, devem ser fortalecidos no Brasil, propondo tecnologias sustentáveis, de preferência neutras em carbono e que preservem nossos recursos naturais.

A sustentabilidade ambiental da inteligência artificial não pode ser uma discussão tardia ou restrita ao setor acadêmico. Deve ser encarada como um dos pilares fundamentais para uma IA mais ética e responsável, estando presente tanto na esfera técnica, quanto nas esferas políticas e educacionais.

Conflitos de interesses

A autora declara que não há interesses financeiros concorrentes ou relações pessoais conhecidas que possam ter influenciado as inferências relatadas neste artigo.

Referências

Alcott, B. Jevons' paradox. *Ecological Economics*, v. 54, n. 1, p. 9-21, 2005. <https://doi.org/10.1016/j.ecolecon.2005.03.020>

Berdardo, F.; Silva, G.; Gritz, M.; Ferro, M.; Schulze, B. **Avaliação do consumo de energia e o impacto da emissão de CO₂ para algoritmos de inteligência artificial**. Petrópolis: Laboratório Nacional de Computação Científica, 2022.

Clemm, C.; Stobbe, L.; Wimalawarne, K.; Druschke, J. Towards Green AI: Current status and future research. **arXiv Preprint**, 2024. <https://doi.org/10.48550/arXiv.2407.10237>

Databricks. **State of Data+AI**: Data intelligence and the race to customize LLMs. San Francisco: Databricks, 2024. Disponível em: <<https://www.databricks.com/sites/default/files/2024-06/state-of-data-ai-report.pdf>>. Acesso em: 30 set. 2024.

de Vries, A. The growing energy footprint of artificial intelligence. **Joule**, v. 7, n. 10, p. 2191-2194, 2023. <https://doi.org/10.1016/j.joule.2023.09.004>

Duncan, G.; Thorpe, D.; Syafiq, M.; Beets, K. **Data Centers 2024 Global Outlook**: AI and the green energy transition will bring new challenges and opportunities. JLL, 2024. Disponível em: <<https://www.jll.com.br/content/dam/jll-com/documents/pdf/research/global/jll-data-center-outlook-global-2024.pdf>>. Acesso em: 10 set. 2024.

Dutta, S.; Innan, N.; Yahia, S.; Shafique, M. AQ-PINNs: Attention-enhanced quantum physics-informed neural networks for carbon-efficient climate modeling. **arXiv Preprint**, 2024. <https://doi.org/10.48550/arXiv.2409.01626>

EPE - Empresa de Pesquisa Energética. **Balanco Energético Nacional (BEN)**: relatório síntese 2024 - Ano base 2023. Brasília: EPE, 2024. Disponível em: <https://www.epe.gov.br/sites-pt/publicacoes-dados-abertos/publicacoes/PublicacoesArquivos/publicacao-819/topico-715/BEN_Síntese_2024_PT.pdf>. Acesso em: 03 out. 2024.

García-Martín, E.; Rodrigues, C. F.; Riley, G.; Grahm, H. Estimation of energy consumption in machine learning. **Journal of Parallel and Distributed Computing**, v. 134, p. 75-78, 2019. <https://doi.org/10.1016/j.jpdc.2019.07.007>

Gartner. **Hype cycle for emerging technologies highlights developer productivity, total experience, AI and security**. Stanford: Gartner, 2024.

Global Energy Monitor. **Global wind power tracker report**. Covina: Global Energy Monitor, 2024. Disponível em: <<https://globalenergymonitor.org>>. Acesso em: 03 out. 2024.

Google. **Relatório de sustentabilidade 2024**. Mountain View: Google Inc., 2024. Disponível em: <<https://www.google.com/sustainability/report2024>>. Acesso em: 02 out. 2024.

IEA - International Energy Agency. **Global data centre energy demand by data centre type, 2010-2022**. Paris: IEA, 2020. Disponível em: <<https://www.iea.org/data-and-statistics/charts/global-data-centre-energy-demand-by-data-centre-type-2010-2022>>. Acesso em: 20 set. 2024.

InfoQ. Investimentos em IA para redução de emissões de carbono até 2030. Relatório, 2024. Disponível em: <<https://www.infoq.com/>>. Acesso em: 12 set. 2024.

Li, P.; Yang, J.; Islam, M.; Ren, S. Making AI less *thirsty*: Uncovering and addressing the secret water footprint of AI models. **arXiv Preprint**, 2023. <https://doi.org/10.48550/arXiv.2304.03271>

Lopes, A. Brasil concentra 75% dos investimentos previstos para *data centers* e inteligência artificial. Exame, 2024. Disponível em: <<https://exame.com/inteligencia-artificial/brasil-concentra-75-dos-investimentos-previstos-para-data-centers-e-inteligencia-artificial/>>. Acesso em: 29 nov. 2024.

- Luccioni, A. S.; Viguier, S.; Ligozat, A.-L. Estimating the carbon footprint of BLOOM, a 176B parameter language model. **Journal of Machine Learning Research**, v. 24, p. 1-15, 2023.
- Maslej, N.; Fattorini, L.; Perrault, R.; Parli, V.; Reuel, A.; Brynjolfsson, E.; Etchemendy, J.; Ligett, K.; Lyons, T.; Manyika, J.; Niebles, J. C.; Shoham, Y.; Wald, R.; Clark, J. **The AI Index 2024 Annual Report**. Stanford: AI Index Steering Committee, Institute for Human-Centered AI, Stanford University, 2024. Disponível em: <https://aiindex.stanford.edu/wp-content/uploads/2024/05/HAI_AI-Index-Report-2024.pdf>. Acesso em: 10 set. 2024.
- Microsoft. **How AI can enable a sustainable future**. Reino Unido: PWC, 2023. Disponível em: <<https://www.pwc.com/gx/en/issues/analytics/assets/pwc-ai-analysis-sizing-the-prize-report.pdf>>. Acesso em: 10 set. 2024.
- Olabi, A. G.; Abdelghafar, A. A.; Maghrabie, H. M.; Sayed, E. T.; Rezk, H.; Al Radi, M.; Obaideen, K.; Abdelkareem, M. A. Application of artificial intelligence for prediction, optimization, and control of thermal energy storage systems. **Thermal Science and Engineering Progress**, v. 39, 101730, 2023. <https://doi.org/10.1016/j.tsep.2023.101730>
- Schwartz, R.; Dodge, J.; Smith, N. A.; Etzioni, O. Green AI. **arXiv Preprint**, 2019. <https://doi.org/10.48550/arxiv.1907.10597>
- Stamoulis, D.; Cai, E.; Juan, D.-C.; Marculescu, D. HyperPower: Power- and memory-constrained hyper-parameter optimization for neural networks. Proceedings of the 2018 Design, Automation, and Test in Europe Conference, Dresden, Germany, p. 19-24, 2018. <https://doi.org/10.23919/DATE.2018.8341973>
- Stanford University. **Artificial intelligence**: Index report 2024. Stanford: Stanford University, 2024. Disponível em: <https://aiindex.stanford.edu/wp-content/uploads/2024/05/HAI_AI-Index-Report-2024.pdf>. Acesso em: 20 set. 2024.
- Strubell, E.; Ganesh, A.; McCallum, A. Energy and policy considerations for deep learning in NLP. Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics, Florence, Italy, p. 3645-3650, 2019.
- Team Ciente. Red AI vs Green AI. **Medium**, 2024. Disponível em: <<https://medium.com/@ciente/red-ai-vs-green-ai-d7c9e4c6e6af>>. Acesso em: 30 set. 2024.
- Uptime Institute. **Global data center survey 2022**: Resiliency remains critical in a volatile world. Singapore: Uptime Institute Intelligence, 2022. Disponível em: <<https://uptimeinstitute.com/resources/research-and-reports/uptime-institute-global-data-center-survey-results-2022>>. Acesso em: 20 set. 2024.
- Verdecchia, R.; Sallou, J.; Cruz, L. A systematic review of Green AI. **WIREs Data Mining and Knowledge Discovery**, v. 13, n. 4, e1507, 2021. <https://doi.org/10.1002/widm.1507>



Informação da Licença: Este é um artigo Open Access distribuído sob os termos da Licença Creative Commons Attribution, que permite uso irrestrito, distribuição e reprodução em qualquer meio, desde que a obra original seja devidamente citada.